1 COMUNICACIÓN ENTRE PROCESOS

Los procesos con frecuencia necesitan comunicarse con otros procesos. Por tanto es deseable tener mecanismos para esa comunicación en una forma bien estructurada y que no utilice interrupciones. En la literatura puede encontrarse el término **comunicación entre procesos** o **IPC** para referirse a estos mecanismos¹.

En la llamada IPC, en general se tienen tres problemas, el primero es cómo un proceso le pasa información a otro. El segundo problema tiene que ver con asegurarse de que dos o más procesos no se estorben mutuamente al efectuar actividades críticas. El tercero se relaciona con la secuencia correcta cuando existen dependencias: Si el proceso A produce datos y el proceso B los imprime, B tiene que esperar hasta que A haya producido algunos datos antes de comenzar a imprimir.

Programación Concurrente

Es el nombre dado a la notación y técnicas de programación utilizados para expresar paralelismo potencial y resolver los problemas de sincronización y comunicación resultantes. Véase [2].

Variables compartidas

Las variables compartidas son objetos a los que más de un proceso tienen acceso; la comunicación por lo tanto, puede proceder con cada proceso referenciando esas variables cuando sea apropiado.

Paso de mensajes

El paso de mensajes involucra intercambio de datos explícito entre dos procesos por medio de un mensaje por medio de un mensaje que pasa de un proceso a otro.

La elección entre variables compartidas y paso de mensajes recae en los diseñadores del lenguaje o del sistema operativo.

Las variables compartidas son faciles de fáciles de soportar si hay memoria compartida entre los procesos. Si no es así, aun se pueden usar si el hardware incorpora un medio de comunicación.

Similarmente, una primitiva de paso de mensajes puede ser soportada a través de memoria compartida o una red de paso de mensajes física.

1.1 Condiciones de Competencia

En un programa concurrente, dos procesos que están colaborando podrían compartir cierto almacenamiento común en el que ambos pueden leer y escribir. El almacenamiento compartido pue estar en la memoria principal o puede ser

 $^{^1{\}rm V\'e}$ ase por ejemplo [4]

un archivo compartido; la ubicación de la memoria compartida no altera la naturaleza de la comunicación ni los problemas que surgen.

Aunque las variables compartidas aparecen como una forma directa de pasar información entre procesos, su uso sin restricción no es confiable y es inseguro debido a problemas de actualizaciones múltiples.

Considere dos procesos actualizando una variable compartida X, con la asignación

$$X = X + 1;$$

En la mayoria de los hardware esto no será ejecutado en una operación **indivisible** (atómica), sino que será implementada en tres instrucciones distintas:

- 1) Cargar el valor de X en algún registro (o en la cima del stack);
- 2) Incrementar en uno el valor en el registro; y
- 3) Almacenar el valor en el registro de regreso a X.

Como las tres operaciones no son indivisibles, dos procesos actualizando la variable simultaneamente podrían entrelazar sus acciones y producir un resultado incorrecto. Por ejemplo, si X era originalmente 5, los dos procesos podrían cargar en sus registros e incrementar y entonces almacenar 6.

Condiciones de competencia/carrera

A las situaciones en las que dos o más procesos leen o escriben datos compartidos y el resultado final depende de quién se ejecuta precisamente cuándo, se denominan **condiciones de competencia**. También se puede encontrar para estas situciones, el término **condiciones de carrera**, véase por ejemplo [3].

Depurar programas que tienen condiciones de carrera no es algo sencillo. Los resultados de la mayoria de las ejecuciones de prueba están bien, pero en algúm momento poco frecuente ocurrirá algo extraño e inexplicable.

¿Qué ocasiona las condiciones de carrera?

La dificultas mencionada en el ejemplo de la variable compartida X ocurrió debido a que un segundo proceso, digamos proceso B empezó a utilizar una variable compartida X antes de que el primer proceso, digamos el proceso A terminara de trabajar con ella.

El problema de evitar las condiciones de carrera se puede formular como sigue: parte del tiempo, un proceso está ocupado realizando cálculos internos y otras cosas que no producen condiciones de carrera. Sin embargo, algunas veces un proceso tiene que acceder a la memoria compartida o a archivos compartidos, o hacer cosas críticas que pueden producir carreras. Esa parte del programa en la que se accede a la memoria compartida se conoce como región crítica o 'bf sección crítica. Si pudieramos ordenar las cosas de manera que dos procesos nunca estuvieran en sus regiones críticas al mismo tiempo, podríamos evitar las carreras.

La clave para evitar problemas aquí y en muchas otras situaciones en las que se involucran la memoria compartida, los archivos compartidos y cualquier otro recurso compartido es buscar alguna manera de evitar que más de un proceso lea y escriba los datos compartidos al mismo tiempo. Dicho en otras palabras, lo que necesitamos es **exclusión mutua**, cierta forma de asegurar que si un proceso está utilizando una variable o archivo compartido, los demás procesos se excluirán de hacer lo mismo.

1.1.1 Exclusión mutua son con espera activa

Existen varios enfoques para lograr la exclusión mutua, de manera que mientras un proceso esté ocupado actualizando la memoria compartida en su región crítica, ningún otro proceso pueda entrar a su propia región crítica y ocasionar problemas.

Inhabilitación de interrupciones

La solución más sencilla es hacer que cada proceso inhabilite las interrupciones justo después de ingresar en su región crítica y vuelva a habilitarlas justo antes de salir de ella. Con las interrupciones inhabilitadas, no pueden ocurrir interrupciones de reloj. Después de todo, la CPU sólo se conmuta de un proceso a otro como resultado de interrupciones de reloj o de otro tipo, y con las interrupciones desactivadas la CPU no se conmutará a ningún otro proceso. Así, una vez que un proceso ha inhabilitado las interrupciones, puede examinar y actualizar la memoria compartida sin temor a que otro proceso intervenga.

Este enfoque casi nunca resulta atractivo, porque no es prudente conferir a los procesos de usuario la facultad de desactivar las interrupciones. Supongamos que uno de ellos lo hiciera, y nunca habilitara las interrupciones otra vez. Esto podría terminar con el funcionaminto del sistema. Además si el sistema es multiprocesador, con dos o más CPU, la inhabilitación de las interrupciones afectaría solo a la CPU que ejecutara la instrucción de inhabilitación; las demás seguirían con las interrupciones habilitadas y podrían acceder a la memoria compartida.

Por otro lado, en muchos casos es necesario que el kernel mismo inhabilite las interrupciones durante unas cuantas instrucciones mientras actualiza variables o listas. Si ocurriera una interrupción en un momento en que la lista de procesos listos, por ejemplo, está en un estado inconsistente, ocurrirían condiciones de competencia. La conslusión es: la inhabilitación de interrupciones suele ser una técnica util dentro del sistema operativo mismo pero no es apropiada como mecanismo de exclusión mutua general para los procesos de usuario.

En la búsqueda de soluciones al problemas de exclusión mutua se han propuesto dos tipos de enfoque: soluciones no usan ayuda del hardware y soluciones que si usan ayuda del hardware. Las primeras pretenden ser más portables y se conocen como soluciones software, mientras que las segundas pretenden ser más simples. Exploraremos superficialmente primero el tipo de solución software y después el tipo de solución que si usa ayuda del hardware.

Variables de candado

Supongamos que tenemos una sola variable (de candado/lock) compartida cuyo valor inicial es 0. Cuando un proceso quiere entrar en su región crítica, lo primero que hace es probar el candado. Si el candado es 0, el proceso le asigna 1 y entra en su región crítica; sie s 1, el proceso espera hasta que el candado vuelve a ser 0. Así, un 0 significa que ningún proceso está en su región crítica.

Desafortunadamente, esta idea contiene exactamente el mismo defecto fatal que vimos en el ejemplo de X=X+1. Supongamos que un proceso lee el candado y ve que es 0. Antes de que este proceso pueda asignar 1 al candado, se planifica otro proceso, el cual se ejecuta y asigna 1 al candado. Cuando el primer proceso continúa su ejecución, asignará 1 al candado, y dos procesos estarán en su región crítica al mismo tiempo.

Podría pensarse que este problema puede superarse leyendo priemro el valor del candado, y verificándolo otra vez justo antes de guardadr el 1 en él, pero esto nno sirve de nada. La competencia ocurriría entonces si el segundo proceso modifica el candado justo después de que el primer proceso terminó su segunda verificación.

Alternancia estricta

Un algoritmo de alternancia estricta se muestra a continuación

```
while(TRUE){
  while(turn!=0);/* esperar */
  critical_region_0();
  turn=1;
  noncritical_region_0();
}

(a)

while(TRUE){
  while(turn!=1);/* esperar */
  critical_region_1();
  turn=0;
  noncritical_region_1();
}

(b)
```

La variable interna turn, que inicialmente es 0, indica a quien le toca entrar en la región crítica y examinar o actualizar la memoria compartida. En un principio, el proceso 0 inspecciona turn, ve que es 0, y entra en su región crítica. El proceso 1 también ve que turn es 0 y se mantiene en un ciclo corto probando turn continuamente para detectar el momento en que cambia a 1. Esta prueba continua de una variable hasta que adquiere algún valor se denomina **espera activa**, y normalmente debe evitarse, ya que desperdicia tiempo de CPU. La espera activa solo debe usarse cuando exista una expectativa razonable de que la espera será corta.

Cuando el proceso 0 sale de la región crítica, asigna 1 a turn, a fin de que el proceso 1 pueda entrar en su región crítica. Supongamos que el proceso 1 termina su región crítica rápidamente, de modo que ambos procesos están en sus regiones no críticas, y turn vale 0. Ahora el proceso 0 ejecuta su ciclo completo rápidamente, regresando a su región no crítica y regresa al principio

 $^{^2\}mathrm{En}$ el ambito de la programación en lenguaje ensamblador se conoce con el nombre de polling.

de su ciclo después de haber asignado 1 a turn. Luego el proceso 0, termina su región no crítica y regresa al principio de su ciclo. Desafortunadamente, no puede entrar en su región crítica porque turn es 1 y el proceso 1 está ocupado en su región no crítica. Dicho de otro modo, la alternancia de turnos no es una buena idea cuando un proceso cuando un proceso es mucho más lento que el otro. Así pues, el proceso 0 está siendo bloqueado por un proceso que no está en su región crítica. De hecho, esta solución requiere que los dos procesos se alternen extrictamente en el ingreso a sus regiones críticas.

La instrucción TSL

Ahora examinaremos una propuesta que requiere un poco de ayuda del hardware. Muchas computadoras, sobre todo las diseñadas pensando en múltiples procesadores, tienen una instrucción TEST AN SET LOCK (TSL, probar y fijar Lock) que funciona como sigue. La instrucción lee el contenido de la palabra en memoria, lo coloca en un registro y luego almacena un valor distinto de cero en esa dirección de memoria. Se garantiza que las operaciones de leer la palabra y guardar el valor en ella son indivisibles; ningún otro procesador puede acceder a la palabra de memoria en tanto la instrucción no haya terminado. La CPU que ejecuta la instrucción TSL pone un candado al bus de memoria para que ninguna otra CPU pueda acceder a la memoria en tanto no termine.

Para usar la instrucción TSL creamos una variable compartida lock a fin de cordinar el acceso a la memoria compartida. Cuando lock es 0, cualquier proceso puede asignarle 1 usando la instrucción TSL y luego leer o escribir la memoria compartida. Cuando el proceso termina, asigna otra vez 0 a lock usando una instrucción MOVE ordinaria.

¿Cómo podemos usar esta instrucción para evitar que dos procesos entren simultaneamente en sus regiones críticas? La solución se da a continuación:

enter_region:

```
TSL register,lock | copiar lock en register y asignarle 1
CPM register,#0 | !?'era lock 0?

JNE enter_region | si no era cero, se asigno 1 a lock y se ejecuta ciclo | volver al invocador; se entro en la region critica
```

leave_region:

MOVE lock,#0 | guardar un 0 en lock ret | volver al invocador

enter_region es una subrutina de cuatro instrucciones escrita en un lenguaje ensamblador ficticio (pero típico). La primera instrucción copia el valor antiguo de lock en el registro y luego asigna 1 a 'tt lock. Luego se compara el valor antiguo con 0. Si es distinto de 0, el candado ya estaba establecido, así que el programa simplemente vuelve al principio y lo prueba otra vez. Tarde o temprano el valor de lock será 0 (cuando el proceso que actualmente está en su región crítica termine lo que está haciendo dentro de dicha región) y la subrutina

regresará, con el candado establecido. Liberar el candado es sencillo, pues basta con almacenar 0 en lock. No se requieren instrucciones especiales.

Ya tenemos una solución al problema de la región crítica que es directa. Antes de entrar en su región crítica un proceso invoca enter_region, la cual realiza espera activa hasta que el candado está libre; luego adquiere el candado y regresa. Después de la región crítica el proceso invoca leave_region, que almacena un 0 en lock.

Implementación en xv6

```
En el archivo x86.h de xv6 encontramos la función
```

También en el archivo spinlock.c se tiene la implementación de spinlocks (locks de giro o candados de giro) para exclusión mutua.

```
// Acquire the lock.
// Loops (spins) until the lock is acquired.
// Holding a lock for a long time may cause
// other CPUs to waste time spinning to acquire it.
void
acquire(struct spinlock *lk)
{
   pushcli(); // disable interrupts to avoid deadlock.
   if(holding(lk))
      panic("acquire");

   // The xchg is atomic.
   // It also serializes, so that reads after acquire are not
   // reordered before it.
   while(xchg(&lk->locked, 1) != 0)
   ;

   // Record info about lock acquisition for debugging.
   lk->cpu = cpu;
```

```
getcallerpcs(&lk, lk->pcs);
// Release the lock.
release(struct spinlock *lk)
{
  if(!holding(lk))
    panic("release");
 1k \rightarrow pcs[0] = 0;
 lk \rightarrow cpu = 0;
 // The xchg serializes, so that reads before release are
  // not reordered after it. The 1996 PentiumPro manual (Volume 3,
  // 7.2) says reads can be carried out speculatively and in
 // any order, which implies we need to serialize here.
  // But the 2007 Intel 64 Architecture Memory Ordering White
  // Paper says that Intel 64 and IA-32 will not move a load
  // after a store. So lock->locked = 0 would work here.
  // The xchg being asm volatile ensures gcc emits it after
  // the above assignments (and after the critical section).
  xchg(&lk->locked, 0);
 popcli();
```

Una nota sobre la instrucción \mathtt{XCHG} de los microprocesadores Intel. Véase [1]. \mathtt{XCHG}

La instrucción de intercambio (XCHG) intercambia el contenido de un registrocon el contenido de cualquier otro registro o una localidad de memoria. La instrucción XCHG no se puede ejecutar en registros de segmento ni con datos de memoria a memoria. Los intercambios son de tamaño byte, palabra o doble palabra (solo en 80386/80486 o superiores). En la siguiente tabla aparecen las formas de la instrucción XCHG

Simbólica	Funciones
XCHG reg,reg	Intercambia registros de byte, palabra y doble palabra
XCHG reg,mem	Intercambia datos en la memoria byte, palabra
	o doble palabra, con datos del registro.

Dormir y despertar

Tanto las soluciones software como las que usan TSL son correctas pero ambas tienen el defecto de requerir espesra activa. En esencia, lo que estas soluciones hacen es lo siguiente: cuando un proceso desea entrar en su región crítica verifica si está permitida la entrada; si no, el proceso simplemente repite un ciclo corto esperando ahasta que lo esté.

Este enfoque no solo desperdicia tiempo de CPU, sino que también puede tener efectos inesperados. Consideremos una computadora con dos procesos, H de alta prioridad, y L de baja prioridad. Las reglas de planificación son tales que H se ejecuta siempre que está en el estado listo. En un momento dado, con L en su región crítica, H queda listo para ejecutarse (p.ej. se completó una operación de E/S). H inicia ahora la espera activa, pero dado que L nunca se planifica mientras H se está ejecutando, L nunca tiene oportunidad de salir de su región crítica, y H permanece en un ciclo infinito. Esta situación se conoce como **problema de inversión de prioridad**. Véase [4] pag. 64.

Examinemos ahora algunas primitivas de comunicación entre procesos que se bloquean (se duermen) en lugar de desperdiciar tiempo de CPU cuando no se les permite entrar en sus regiones críticas. Una de las más sencillas es el par SLEEP y WAKEUP. SLEEP (dormir) es una llamada al sistema que hace que el invocador se bloquee, es decir, se suspenda hasta que otro proceso lo despierte. La llamada WAKEUP (despertar) tiene un parámetro, el proceso que se debe despertar. Como alternativa, tanto SLEEP como WAKEUP pueden tener un parámetro cada uno, una dirección de memoria que sirve para enlazar los SLEEP con los WAKEUP.

El problema productor-consumidor

Como ejemplo de uso de estas primitivas, consideremos el problema de **productor- consumidor** (también conocido como problema de **buffer limitado**). Dos procesos comparten un mismo *buffer* sw tamaño fijo. Uno de ellos, el productor, coloca información en el *buffer*, y el otro, el consumidor, la saca.

Surgen problemas cuando el productor quiere colocar un nuevo elemento en el buffer, pero este ya está lleno. La solución es que el productor se duerma y sea despertado cuando el consumidor haya retirado uno o más elementos. De forma similar, si el consumidor desea sacar un elemento del buffer y ve que está vacio, se duerme hasta que el productor pone algo en el buffer y lo despierta.

Este enfoque parece muy sencillo, pero da lugar a los mismos tipos de condiciones de carrera que se han mencionado antes. Para seguir la pista al númeor de elementos contenidos en el buffer, necesitaremos una variable, count. Si el número máximo de elementos que el buffer puede contener es N, el código del productor primero verificará si count es igual a N. Si es así, el productor se dormirá, si no, el productor agregará un elemento e incrementará count.

El código del consumidor es similar: primero se prueba *count* para ver si es 0. Si es así, el consumidor se duerme; si no, el consumidor saca un elemento y decrementa *count*. Cada uno de estos procesos verifica también si el otro debería estar durmiendo, y si no es así, lo despierta. El código del productor y del consumidor se muestra en la siguiente figura

```
/* generar el siguiente elemento */
   produce_item();
    if(count==N)sleep(); /* si el buffer esta lleno, dormir */
    enter_item();
                         /* colocar elemento en el buffer */
    count=count+1;
                         /* incrementar la cuenta de elementos */
    if(count==1)wakeup(consumer);
  }
}
void consumer(void){
  while(TRUE){
    if(count==0)sleep(); /* si el buffer esta vacio, dormir */
    remove_item();
                         /* remover elemento del buffer */
    count=count-1;
                         /* decrementar la cuenta de elementos */
    if(count==N-1)wakeup(producer);/* estaba lleno el buffer? */
    consume_item();
                         /* imprimir elemento */
 }
}
```

Volvamos ahora a la condición de carrera. Ésta puede ocurrir porque el acceso a count es irrestricto, y podría presentarse la siguiente situación. El 'it buffer está vacio y el consumidor acaba de leer count para ver si es 0. En ese instante, el planificador decide dejar de ejecutar el consumidor temporalmente y comenzar a ejecutar el productor. Éste coloca un elemento en el buffer, incrementa count, y observa que ahora vale 1. Esto implica que antes count valía 0, y por ende que el consumidor está durmiendo, así que el productor invoca wakeup para despertar al consumidor.

Desafortunadamente, el consumidor todavía no estaba dormido lógicamente, de modo que la señal de despertar se pierde. Cuando el consumidor reanuda su ejecución, prueba el valor de count que había leido previamente, ve que es 0 y se duerme. Tarde o temprano el productor llenará el buffer y se dormirá. Ambos seguirán durmiendo eternamente.

La esencia del problema aquí es que se perdió una llamada enviada para despertar a un proceso que (todavía) no estaba dormido. Si no se perdiera, todo funcionaría. Una compostura rápida consiste en modificar las reglas y agregar un **bit de espera de despertar** a la escena. Cuando se envía una llamada de despertar a un proceso que está despierto, se enciende este bit. Después, cuando el proceso trata de dormirse, si el bit de espera de despertar está encendido, se apagará pero el proceso seguirá despierto. El bit de espera de despertar actúa como una alcancia de señales de despertar.

Lamentablemente, si existen tres o más procesos, un bit de espera de despertar es insuficiente. Se podría crear otro "parche" y agregar un segundo bit de espera de despertar, o quizá 8 o 32, pero en principio el problema sigue ahí. **Semáforos**

En 1965, E, W. Dijkstra introdujo un nuevo tipo de variable llamada semáforo.

Un semáforo podría tener el valor 0, indicando que no había señales de despertar guardadas, o alg"un valor positivo si había una o más señales de despertar pendientes.

Dijkstra propuso tener dos operaciones DOWN y UP (generalizaciones de sleep y wakeup, respectivamente). La operación DOWN aplicada a un semáforo verifica si el valor es mayor que 0; de ser así, decrementa el valor (esto es, gasta una señal de despertar almacenada) y continúa. Si el valor es 0, el proceso se pone a dormir sin completar la operación DOWN por el momento. La verificación del valor, su modificación y la acción de dormirse, si es necesaria, se realizan como una sola acción atómica indivisible. Se garantiza que una vez que una operación de semáforo se ha iniciado, ningún otro proceso podrá acceder al semáforo hasta que la operación se haya completado o bloqueado. Esta atomicidad es absolutamente indispensable para resolver los problemas de sincronización y evitar las condiciones de carrera.

La operación UP incrementa el valor del semáforo direccionado. Si uno o más procesos están durmiendo en espera de ese semáforo, imposibilitados de completar una operación DOWN previa, el sistema escoge uno de ellos (p.ej. al azar) y le permite completar su DOWN. Así, después de un UP con un semáforo que tiene procesos durmiendo esperando, el semáforo seguirá siendo 0, pero habrá un proceso menos que se halle en fase de durmiendo esperando. La operación de incrementar el semáforo y despertar un proceso también es indivisible. Ningún proceso se bloquea durante un UP.

Resolución del problema de productor-consumidor usando semáforos Los semáforos resuelven el problema de la señal de despertar perdida, una posible solución se muestra en el siguiente listado de código. Es indispensable que las funciones UP y DOWN se implementen de modo que sean indivisibles. El método normal consiste en implementar UP y DOWN como llamadas al sistema, para que el sistema operativo inhabilite brevemente todas las interrupciones mientras prueba el semáforo, lo actualiza y pone el proceso a dormir, si es necesario. Todas estas acciones requieren sólo unas cuantas instrucciones, así que la inhabilitación de las interrupciones no tiene consecuencias adversas. Si se están usando múltiples CPU, cada semáforo debe estar protegido con una variable de candado (por ejemplo un spinlock), usando la instrucción TSL para asegurarse de que sólo una CPU a la vez examine el semáforo. El empleo de una instrucción TSL para evitar que varias CPU accedan al semáforo al mismo tiempo es muy diferente de la espera activa del productor o el consumidor cuando esperan que el otro proceso vacíe o llene el buffer. La operación del semáforo solo toma unos cuantos microsegundos, mientras que si se usa espera activa el productor o el consumidor podrían tardar un tiempo arbitrariamente largo.

```
semaphore full=0;
                                      /* cuenta las ranuras de buffer llenas */
void producer(void){
  int item;
  while(TRUE){
                                      /* TRUE es la constante 1 */
   produce_item(&item);
                                      /* generar algo para ponerlo en el buffer */
                                      /* decrementar el contador empty */
    down(&empty);
    down(&mutex);
                                      /* entrar en la region critica */
                                      /* colocar el nuevo elemento en el buffer */
    enter_item(item);
    up(&mutex);
                                      /* salir de la region critica */
    up(&full);
  }
void consumer(void){
  int item;
  while(TRUE){
                                       /* ciclo infinito */
                                       /* decrementar el contador full */
    down(&full);
                                      /* entrar en la region critica */
    down(&mutex);
                                      /* sacar elemento del buffer */
   remove_item(&item);
    up(&mutex);
                                       /* salir de la region critica */
    up(&empty);
                                       /* incrementar el contador de ranuras vacias */
    consume_item(item);
                                       /* hacer algo con el elemento */
 }
}
```

Esta solución usa tres semáforos: uno llamado full para contar el número de ranuras que están llenas, uno llamado empty para contar el número de ranuras que están vacias, y otro llamado mutex para asegurarse de que el productor y el consumidor no accedan al buffer al mismo tiempo. full inicialmentevale 0, empty inicialmente es igual al numero de ranuras del buffer y mutex inicialmente es 1. Los semáforos a los que se asigna 1 como valor inicial y son utilizados por dos o más procesos para asegurar que sólo uno de ellos pueda entrar en su región crítica al mismo tiempo se denominan semáforos binarios. Si cada proceso ejecuta DOWN justo antes de entrar en su región crítica, y UP justo después de salir de ella, la exclusión mutua está garantizada. (Véase [4], pag. 68 para una indicación sobre cómo usar los semáforos para "ocultar" las interrupciones).

En el ejemplo del código anterior realmente se usan los semáforos de dos formas distintas. Esta diferencia es lo siguiente: el semáforo mutex se usa para exclusión mutua: está diseñado para garantizar que solo un proceso a la vez estará leyendo o escribiendo el buffer y las variables asociadas a él. Esta eclusión mutua es necesaria para evitar el caos.

El otro uso de los semáforos es la **sincronización**. Los semáforos **full** y **empty** se necesitan para garantizar que ciertas secuencias de sucesos ocurran o no ocurran. En este caso, los semáforos aseguran que el productor dejará de ejecutarse cuando el buffer esté lleno y que el consumidor dejará de ejecutarse

cuando el buffer esté vacio. Este uso es diferente de la exclusión mutua. Aunque los semáforos se han usado desde 1965, aun se siguen efectuando investigaciones sobre su uso y en la actualidad se pueden encontrar en kernels de sistemas operativos ya sade tiempo real o no, podemos verlos por ejemplo en el kernel linux.

References

- [1] Barry B. Brey, "Los Microprocesadores Intel, Arquitectura, programación e interfases." Prentice-Hall 3^a Edición, 1995.
- [2] Alan Burns, Andy Wellings, "Real-Time Systems and Programming Languages", Addison-Wesley, 3^a Edición, Pearson Education Limited 2001.
- [3] Jonathan Corbet, Alessandro Rubini, Greg Kroah-Hartman, "Drivers en Linux, Técnicas y soluciones para el desarrollo de Controladores", O'Reilly Anaya Multimedia, 2005.
- [4] Andrew S. Tanenbaum, "Sistemas Operativos, Diseño e implementación," Editorial Pearson, 2002.